Plugin de Alinhamento Interativo de Ontologias de Cibersegurança com Abordagens de Aprendizado de Máquina e K-Means*

Abstract

Technological advancements, combined with economic, political, and social transformations, have significantly contributed to the increasing complexity of Information Systems (IS). This complexity is associated with systems that integrate physical and cyber components through sensors, computational resources, and communication networks, commonly known as Cyber-Physical Systems (CPS). The rapid growth of CPS applications has brought challenges related to security, interoperability, and reliability, especially in critical infrastructures and sensitive functionalities.These challenges can be addressed through the use of ontologies in cybersecurity, which help organize and standardize knowledge to facilitate system integration. However, integrating these ontologies may expose vulnerabilities, allowing skilled attackers to exploit heterogeneity issues and inject malicious code. This study presents an Interactive Ontology Matching Plugin, based on the K-Means algorithm combined with three machine learning classifiers, aiming to address heterogeneity problems in the integration of cybersecurity ontologies within nuclear power plant systems. This approach enables secure and efficient ontology matching, ensuring the continuous and protected operation of nuclear power plants against potential cyber-attacks.

Keywords

Cyber-Physical Systems, Ontology Matching, Machine Learning, K-Means, Cybersecurity, Nuclear Power Plants

1. Introdução

Os avanços tecnológicos e as transformações socioeconômicas têm aumentado a complexidade dos Sistemas de Informação (SI), exigindo que as organizações adotem padrões tecnológicos mais sofisticados para se adaptar às mudanças, mantendo a qualidade, aumentando a produtividade e otimizando custos. [1]. Essa crescente complexidade está associada a uma categoria de sistemas que integra componentes cibernéticos e físicos por meio de tecnologias como sensores, recursos computacionais e redes de comunicação, amplamente conhecida como Sistema Ciberfísico (do inglês, *Cyber-Physical System* – CPS) [2, 3]. Os CPS estão diretamente associados ao conceito de Indústria 4.0 [4], que visa combinar tecnologias e conhecimentos para proporcionar autonomia, confiabilidade, sistematicidade e controle sem intervenção humana [5]. A Figura 1 apresenta uma representação conceitual da Indústria 4.0.

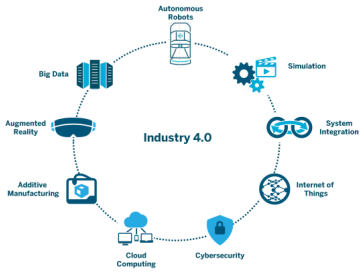

Figure 1: Representação do conceito da insutria 4.0.

Esses sistemas são aplicados em contextos como Internet das Coisas (*IoT*), Big Data, tecnologias inteligentes, computação em nuvem, entre outros. O CPS constitui a base para o desenvolvimento de diversas áreas emergentes, como manufatura inteligente, medicina inteligente, edifícios e infraestruturas inteligentes, cidades inteligentes, veículos autônomos, dispositivos vestíveis, sistemas móveis, defesa,

Proceedings of the 18th Seminar on Ontology Research in Brazil (ONTOBRAS 2025) and 9th Doctoral and Masters Consortium on Ontologies (WTDO 2025), São José dos Campos (SP), Brazil, September 29 – October 02, 2025.

© 2025 Copyright for this paper by its authors. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).

meteorologia, entre outras [5]. O rápido crescimento das aplicações baseadas em CPS tem gerado uma série de problemas relacionados à segurança e à confidencialidade, especialmente no que se refere à integração de infraestruturas críticas e funcionalidades sensíveis [5]. Por exemplo, quando as usinas nucleares Angra 1, Angra 2 e, futuramente, Angra 3, operadas pela Eletronuclear[1], necessitarem interoperar de forma integrada, será essencial assegurar a interconectividade e a interação entre seus sistemas, de modo a garantir uma gestão e controle adequados de seus processos e ambientes computacionais [6, 7, 8].

Na Figura 2 são apresentadas as Usinas Termonucleares Angra 1 e Angra 2 e o Centro Nuclear Almirante Álvaro Alberto (CNAAA) [2].

Figure 2: À esquerda, as instalações das Usinas Termonucleares Angra 1 e Angra 2; à direita, o complexo do Centro Nuclear Almirante Álvaro Alberto (CNAAA), composto pelas usinas Angra 1, Angra 2 e Angra 3 (em fase de construção).

Nesse sentido, a ocorrência de falhas de segurança da informação, como perda ou acesso não autorizado a dados confidenciais durante a comunicação entre os sistemas ciberfísicos e as respectivas plantas dessas usinas, pode colapsar o sistema como um todo e acarretar diversos prejuízos para o negócio.

Diante desse cenário, é imprescindível implementar mecanismos e/ou tecnologias que assegurem que a comunicação entre os sistemas e suas respectivas plantas ocorra com base nos princípios da segurança da informação: confidencialidade, integridade e disponibilidade [9]. Para isso, uma ontologia no domínio da segurança cibernética pode ser empregada na construção de um modelo de conhecimento compartilhado entre uma planta de usina nuclear e seus sistemas ciberfísicos.

No entanto, ontologias no domínio da segurança cibernética são frequentemente desenvolvidas com requisitos, escopos e objetivos distintos, o que acarreta desafios relacionados à heterogeneidade semântica. Essa heterogeneidade pode se manifestar, por exemplo, por meio de incompatibilidades semânticas entre ontologias de segurança cibernética aplicadas à proteção de sistemas ciberfísicos (CPS), resultando em interpretações ambíguas, incompletas ou imprevisíveis dos conceitos representados. Tais inconsistências semânticas podem comprometer a confiabilidade do sistema e, mais criticamente, introduzir vulnerabilidades que podem ser exploradas por agentes maliciosos para injeção de código ou manipulação de comportamentos em tempo de execução [10, 11].

Diante desse cenário, deve-se realizar um processo de alinhamento de ontologias para resolver problemas de heterogeneidade na integração de ontologias do domínio de segurança cibernética em plantas de usinas nucleares (i.e., Angra 1 e Angra 2). Isso permitirá o pleno funcionamento de operações integradas dessas usinas, evitando possíveis ataques cibernéticos.

O presente artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica; a Seção 4 expõe a definição do problema; a Seção 5 descreve a solução proposta; a Seção 6 detalha a implementação e os resultados experimentais obtidos; e, por fim, a Seção 7 traz as considerações finais.

[1] https://www.eletronuclear.gov.br/Nossas-Atividades/Paginas/default.aspx
[2] https://www.eletronuclear.gov.br/Nossas-Atividades/Paginas/default.aspx

2. Fundamentação Teórica

2.1. Processo de Alinhamento de Ontologias

O processo de alinhamento de ontologias foca na identificação de mapeamentos entre entidades de duas ontologias e no estabelecimento de um alinhamento como solução para o problema de heterogeneidade [12]. Mas ainda existem muitos erros relacionados aos alinhamentos gerados por abordagens automáticas.

Pode-se destacar algumas limitações, como por exemplo, problemas de detecção dos significados dos termos de forma precisa semanticamente e a abordagem manual é extremamente trabalhosa e bastante demorada. Uma abordagem que é bastante comentada na literatura e tem tido bons resultados devido a sua eficiência, é a abordagem interativa [13]. Tal abordagem considera a participação do especialista do domínio na análise e confirmação se o alinhamento entre as entidades de um par de ontologias é correto ou incorreto e tem como propósito, gerar um alinhamento de boa qualidade.

2.2. Clusterização

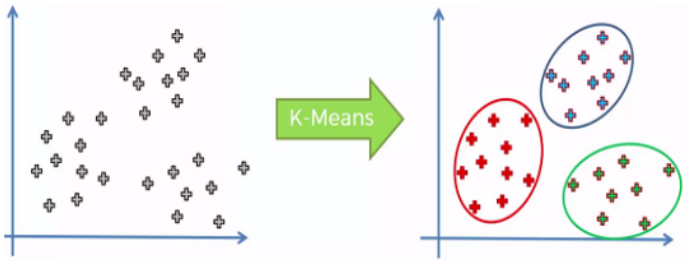

Figure 3: Processo de clusterização por meio do uso do algoritmo K-Means.

O principal objetivo da técnica de clusterização é encontrar grupos semelhantes ou homogêneos em dados, que são chamados de clusters. O agrupamento é guiado pelo princípio que os itens dentro de um cluster devem ser muito semelhantes entre si, porém diferentes entre os clusters [14].

Esta técnica é utilizada, por exemplo, para segmentação de clientes em grupos de demografia semelhantes, padrões de compra para campanhas de marketing direcionadas, detecção de comportamento anômalo, como intrusões de rede não autorizadas, identificando padrões de uso fora dos clusters conhecidos e simplificação de grandes conjuntos de dados agrupando características com valores semelhantes em um número menor de categorias homogêneas.

O algoritmo K-Means é um método de clusterização de aprendizado não supervisionado, ou seja, sem a necessidade de supervisão humana, que particiona um conjunto de dados em grupos separados, onde o valor de k, deve ser pré-determinado [14, 15].

Conforme a Tabela 1, a criação de modelos com esse algoritmo envolve especialmente as seguintes fases:

Table 1
Fases do Algoritmo K-Means

Fase	Descrição
Atribuição	O algoritmo atribui os dados a um conjunto inicial de *K Clusters*.
Atualização	O algoritmo atualiza as atribuições ajustando os limites de cada cluster de acordo com os dados que estão no cluster.
Iterações	O processo de atribuição e atualização ocorre várias vezes até que as atualizações não modifiquem o ajuste de cluster.

O cluster encontra o seu limite. Então, o processo termina e os clusters são finalizados.

2.3. Classificação

A técnica de classificação em Machine Learning representa o processo de categorizar um determinado conjunto de dados [16]. O processo começa com a previsão da classe de determinados pontos de dados. As classes são muitas vezes referidas como alvo, rótulos ou categorias. Ou seja, tal processo procurar reconhecer padrões.

Dessa forma, os algoritmos de classificação aplicados aos dados de treinamento encontram o mesmo padrão em um conjunto de dados futuros com o objetivo de categorizar este conjunto de dados [16].

Pode-se destacar como exemplo, a detecção de spam em provedores de serviços de e-mail. Um classificador utiliza alguns dados de treinamento para entender como determinadas variáveis de entrada se relacionam com a classe. Assim, os e-mails conhecidos como spam e não spam são usados como dados de treinamento. Nesse sentido, o classificador pode ser usado para detectar um e-mail desconhecido como spam ou não spam. Como exemplos de classificadores temos o *Perceptron*, o *Naive Bayes* e o *Random Forest* [17, 18, 19].

Há muitas aplicações na classificação em muitos domínios, como aprovação de crédito, diagnóstico médico, marketing de destino etc.

3. Trabalhos Relacionados

Os sistemas descritos a seguir foram avaliados na edição de 2024 da *Ontology Alignment Evaluation Initiative* (OAEI), no contexto da trilha *Conference*, e representam diferentes abordagens para o alinhamento de ontologias:

- **OntoMatch**: Em um estudo sobre os resultados do sistema *OntoMatch*, Sampels (2024) apresenta um método que combina algoritmos de busca em grafos com *prompting* zero-shot em modelos de linguagem de grande porte (LLMs). A abordagem envolve etapas iterativas de seleção de candidatos com base na vizinhança em grafos, extração e verbalização do contexto semântico, geração de *prompts* estruturados a partir de templates específicos e avaliação com LLMs, além da aplicação de um filtro de cardinalidade para garantir mapeamentos 1:1. A similaridade entre conceitos é calculada com *embeddings* SBERT. No dataset *Conference*, o *OntoMatch* alcançou precisão de 0,88, medida-F de 0,70 e cobertura de 0,59 na avaliação baseada no alinhamento de referência (ra1), com a métrica de incerteza modelada como variável contínua. O sistema possui arquitetura modular, permitindo a substituição de componentes, inclusive dos LLMs, facilitando futuras adaptações para outras trilhas da OAEI.
- **Alin**: Silva et al. (2024) apresentam o sistema *Alin*, voltado ao alinhamento interativo de ontologias. Nesta versão, o *Alin* incorporou melhorias nos analisadores lexicais e passou a utilizar o ChatGPT para filtrar mapeamentos, com o objetivo de reduzir as interações com especialistas sem comprometer significativamente a qualidade do alinhamento. O processo segue cinco etapas principais: seleção de mapeamentos, filtragem, consulta ao especialista, propagação e iteração até a finalização. Na trilha *Conference*, o *Alin* obteve desempenho superior ao *LogMap* em termos de *F-measure* (0,794 contra 0,723), embora tenha exigido maior número de interações com o especialista (187 contra 82), evidenciando uma troca entre qualidade do alinhamento e esforço humano.
- **MDMapper**: Avaliado com foco em modelos de dados mestres (MDM), o sistema *MDMapper*, de Liu et al. (2024) , combina técnicas tradicionais de correspondência de ontologias com métodos inovadores, como medidas de similaridade baseadas em strings e transformadores (Sentence-BERT), para calcular uma matriz de similaridade global. O sistema identifica correspondências de alta confiança inicialmente e, em seguida, descobre novas correspondências por meio de uma abordagem de gerenciamento de restrições baseada em conflitos. No dataset *Conference*, o *MDMapper* alcançou precisão de 0,69, medida-F de 0,66 e cobertura de 0,64, com a métrica de incerteza modelada como variável contínua.

- **LogMap e LogMapLt**: Jiménez-Ruiz (2024) apresenta os sistemas *LogMap* e *LogMapLt*. O primeiro é um sistema baseado em lógica, desenvolvido desde 2011, conhecido por sua escalabilidade, técnicas de raciocínio e capacidade de minimizar inconsistências lógicas. O segundo é uma versão simplificada, que adota técnicas eficientes de correspondência de strings. No dataset *Conference*, o *LogMap* obteve precisão de 0,80, medida-F de 0,66 e cobertura de 0,57, posicionando-se em quarto lugar na avaliação baseada no alinhamento de referência (ra1), com a métrica de incerteza também modelada como variável contínua.

4. Definição do problema

O alinhamento entre ontologias no domínio da segurança cibernética aplicadas a plantas de usinas nucleares é fundamental para viabilizar o pleno funcionamento das operações, minimizando riscos associados a ataques cibernéticos [12, 10]. Muitas abordagens foram propostas para encontrar um alinhamento preciso e completo e vários trabalhos na literatura destacam que o processo de alinhamento de ontologias não pode ser totalmente automatizado.

Nesse sentido, a intervenção humana é importante para verificar ou ajustar os mapeamentos produzidos pelo algoritmo utilizado. Dessa forma, considera-se que a combinação da validação baseada na expertise do usuário com técnicas automáticas proporciona resultados mais robustos e confiáveis do que aqueles obtidos exclusivamente por métodos automáticos [24, 25].

Para Falconer et al. (2006), esse é o caminho a seguir, pois muitos trabalhos acadêmicos se concentram apenas no algoritmo em si, ignorando amplamente a análise do usuário sobre os mapeamentos propostos por esses algoritmos e a criação de novos mapeamentos.

5. Solução Proposta

Foi desenvolvido um programa de Alinhamento Interativo de Ontologias denominado *VIEW* (*Interactive Ontology Matching View*), fundamentado no conceito de *view*, amplamente utilizado em sistemas de bancos de dados. O sistema emprega o algoritmo *K-Means* para agrupar mapeamentos semelhantes em *clusters* e seleciona um mapeamento representativo de cada *cluster* para ser avaliado por especialistas humanos [26, 27, 28].

A Tabela 2 apresenta as regras de atualização dos valores de similaridade e os critérios de classificação dos mapeamentos adotados para o *Conference dataset*.

Table 2
Regras de Atualização de Similaridade e Classificação de Mapeamentos

Condição	Procedimento Aplicado
Avaliação do especialista igual a *True*	Os mapeamentos pertencentes ao mesmo *cluster* têm seus valores de similaridade atualizados por meio da multiplicação por um parâmetro pré-definido (↑).
Avaliação do especialista igual a *False*	Os mapeamentos pertencentes ao mesmo *cluster* têm seus valores de similaridade atualizados por meio da subtração de um parâmetro estabelecido (↓).
Média das métricas de similaridade ≥ 1	O mapeamento é classificado como *True* e transferido para o conjunto de mapeamentos corretos.
Média das métricas de similaridade ≤ 0	O mapeamento é classificado como *False* e transferido para o conjunto de mapeamentos incorretos.

A execução do plugin continua até que o conjunto de mapeamentos em fase de *clusterização* esteja vazio.

Na Figura 4, apresenta-se o diagrama de atividades em UML (Unified Modeling Language) do plugin *VIEW*.

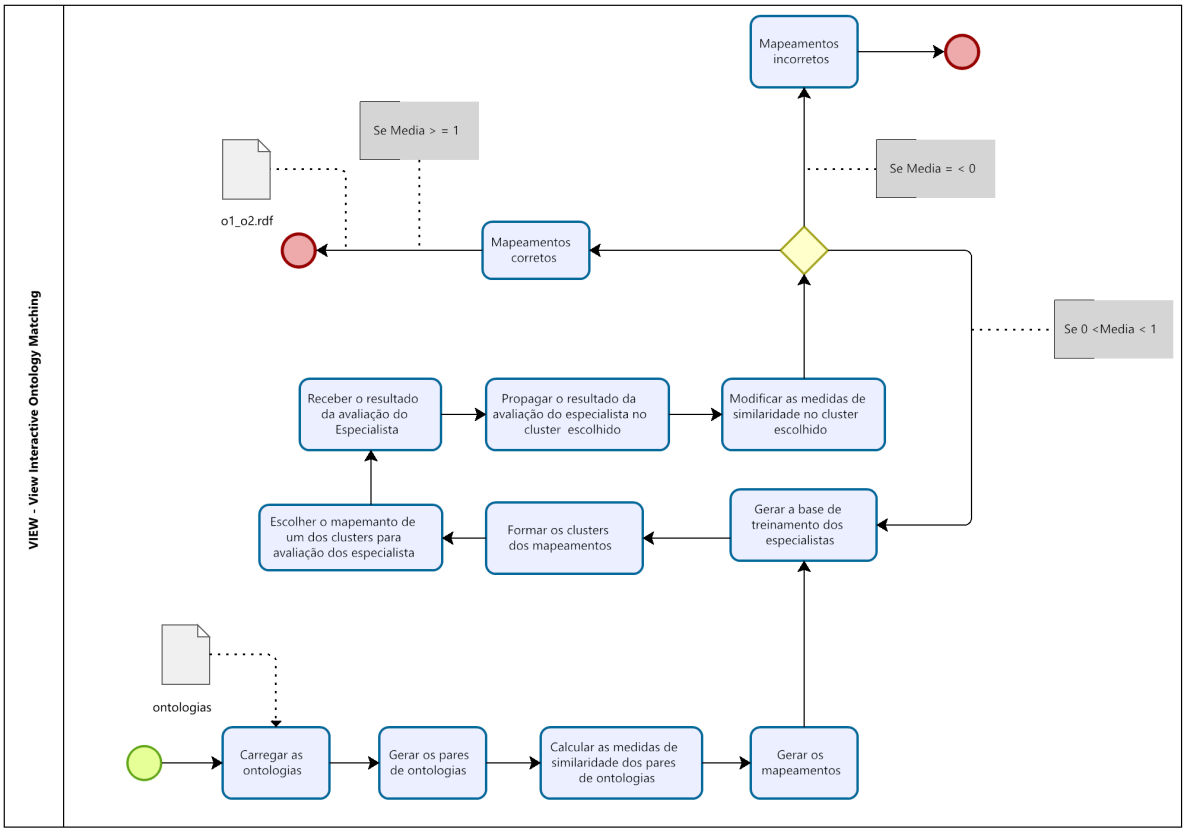

Figure 4: Diagrama de atividades em UML do plugin *VIEW*.

6. Implementação e Resultados Experimentais

O plugin *VIEW* foi implementado utilizando as seguintes APIs em Java:

- Weka, com rotinas estatísticas e de KDD [29];
- Simmetrics, com métricas de similaridade baseadas em strings [30];
- WS4J, com métricas linguísticas baseadas na Wordnet [31]; e
- Alignment, que contém rotinas para manipulação de ontologias escritas em OWL [32].

A avaliação deste plugin foi realizada com base nos resultados da Trilha Interativa do *Conference dataset*, no contexto da OAEI, considerando as edições da Conferência *Ontology Matching* de 2022[3], 2023[4] e 2024[5]. O período de 2022 a 2024 foi selecionado para comparação por abranger o maior número de sistemas participantes.

A OAEI é uma iniciativa internacional voltada à avaliação de sistemas de alinhamento de ontologias, com o objetivo de comparar o desempenho desses sistemas por meio da publicação de resultados padronizados e sistematicamente analisados [33, 34, 35].

[3]https://om.ontologymatching.org/2022/
[4]https://om.ontologymatching.org/2023/
[5]https://om.ontologymatching.org/2024/

A OAEI disponibiliza alinhamentos de referência para diversos domínios de avaliação. Para este estudo, foi selecionado o conjunto de dados do domínio de conferências acadêmicas. O *Conference dataset* é composto por sete ontologias: **Cmt, ConfTool, Edas, Ekaw, Iasted, Sigkdd** e **Sofsem**.

Existe um alinhamento de referência original, que pode ser baixado para testes com programas de alinhamento de ontologias[6]. Esse alinhamento contempla pares entre todas as ontologias do dataset, totalizando 21 alinhamentos de referência.

Com base nesses alinhamentos, foram avaliados os resultados obtidos pelo plugin *View*, considerando as métricas de Precisão, Medida-F e Cobertura.

Conforme apresentado na Tabela 3, a medida de Precisão do *VIEW* foi superior à dos demais sistemas de alinhamento de ontologias avaliados nesta trilha. Em domínios sensíveis, como o de plantas de usinas nucleares, a precisão é um fator relevante, pois mapeamentos incorretos podem acarretar consequências graves, tornando os sistemas vulneráveis a ameaças e impactos decorrentes de ataques cibernéticos. Além disso, a precisão está diretamente ligada à confiança que os técnicos depositam nesses sistemas, uma vez que decisões baseadas em mapeamentos equivocados podem comprometer a segurança operacional e expor falhas significativas. Dessa forma, destaca-se a importância de utilizar um programa que apresente alta precisão, especialmente em contextos tão críticos e suscetíveis a diferentes tipos de ataques.

Table 3
Resultados do experimento com o plugin View, comparados aos dos participantes da Trilha Interativa da OAEI 2024 – Dataset Conference. A avaliação baseou-se no alinhamento de referência (ra1), com os resultados apresentados na seção da tabela referente à métrica de incerteza modelada como variável contínua [35].

Rank	Sistema	Precisão	Medida F	Cobertura
1	VIEW	1.00	0.74	0.61
2	OntoMatch	0.88	0.70	0.59
3	ALIN	0.87	0.71	0.60
4	LogMap	0.80	0.66	0.57
5	LogMapLt	0.72	0.67	0.63
6	MDMapper	0.69	0.66	0.64
7	Matcha	0.68	0.71	0.75
8	TOMATO	0.61	0.59	0.56

Table 4
Resultados do experimento com o plugin *VIEW*, comparados aos dos participantes da Trilha Interativa da OAEI 2023 – Dataset Conference. A avaliação baseou-se no alinhamento de referência (ra1), com os resultados apresentados na seção da tabela referente à métrica de incerteza modelada como variável contínua [34].

Rank	Sistema	Precisão	Medida F	Cobertura
1	VIEW	1.00	0.74	0.61
2	LSMatch	0.88	0.67	0.54
3	ALIN	0.87	0.71	0.60
4	AMD	0.86	0.67	0.55
5	LogMap	0.80	0.66	0.57
6	PropMatch	0.73	0.13	0.07
7	LogMapLt	0.72	0.67	0.63
8	SORBETMatcher	0.69	0.70	0.72
9	GraphMatcher	0.65	0.73	0.84
10	Matcha	0.64	0.69	0.74
11	TOMATO	0.60	0.62	0.64
12	OLaLa	0.57	0.63	0.70

[6] https://oaei.ontologymatching.org/2022/conference/

Figure 5: Resultados obtidos do plugin *VIEW* em comparação com os sistemas que participaram da Trilha Interativa - Dataset *Conference* - OAEI'2024.

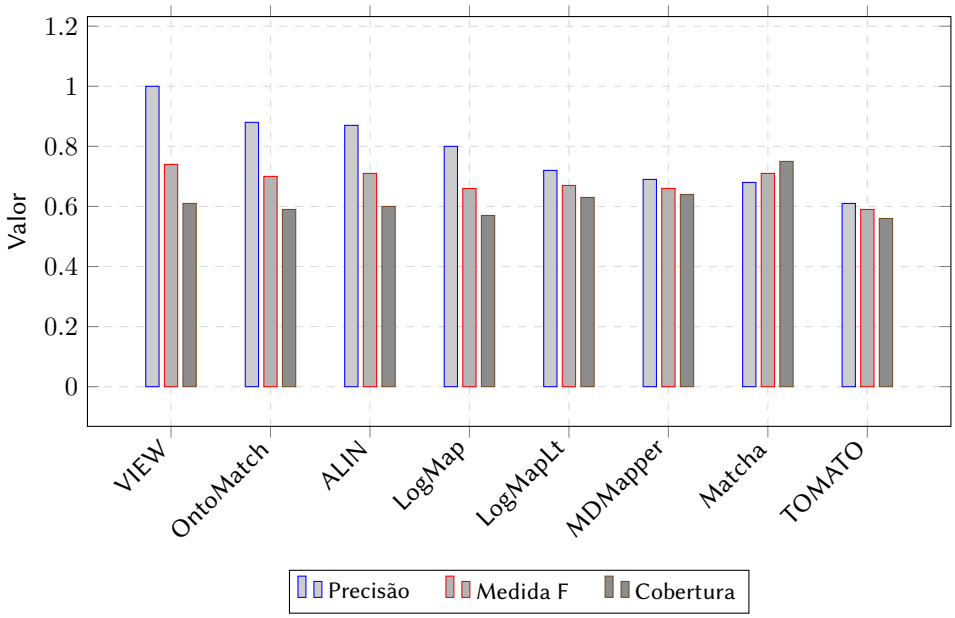

Figure 6: Resultados obtidos do plugin *VIEW* em comparação com os sistemas que participaram da Trilha Interativa - Dataset *Conference* - OAEI'2023.

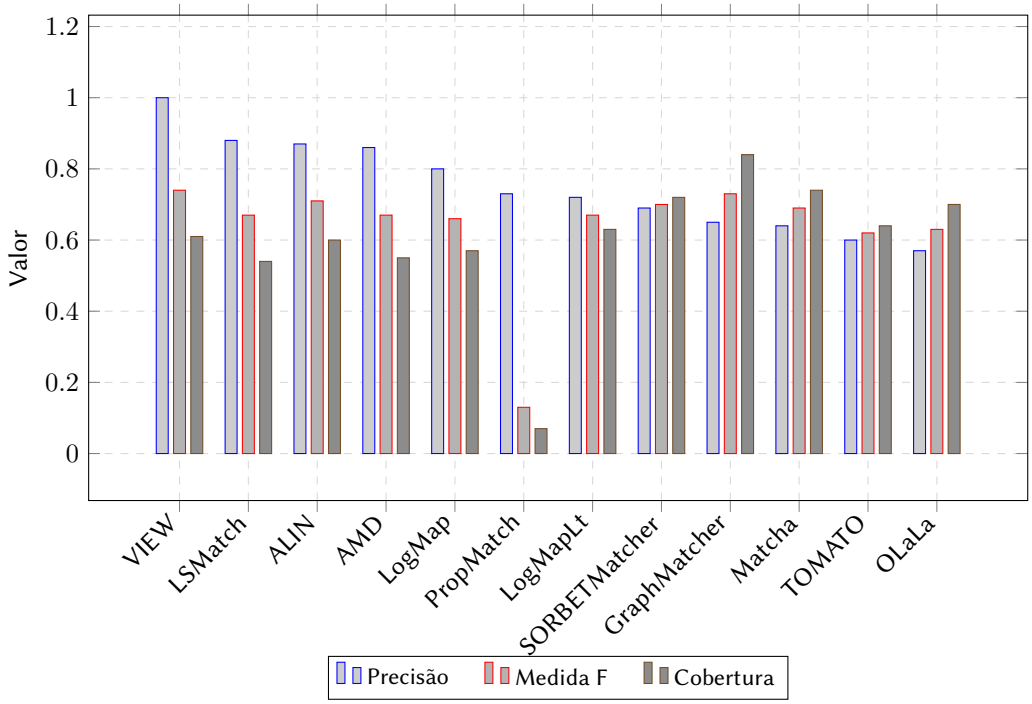

Conforme demonstrado na Tabela 4 e na Figura 6, as medidas de Precisão e Medida-F do *VIEW* superaram as dos demais sistemas de alinhamento de ontologias avaliados nesta trilha. Esses resultados indicam que as informações integradas e analisadas a partir dos mapeamentos cobrem de forma abrangente os aspectos críticos e preservam a integridade dos sistemas envolvidos. A ocorrência de falhas nesses processos pode gerar impactos consideráveis à segurança operacional, especialmente em ambientes sensíveis. Portanto, torna-se imprescindível assegurar elevados índices de Precisão e Medida-F, a fim de garantir a gestão eficiente e o controle seguro dos processos e das infraestruturas computacionais [6, 7, 8].

No que se refere à Trilha Interativa do Dataset *Conference* da OAEI 2022, conforme demonstrado na Tabela 5, o *VIEW* alcançou a primeira colocação na medida de Precisão e a segunda colocação nas medidas de Cobertura e Medida-F, conforme ilustrado na Figura 7. Esses resultados evidenciam a robustez do programa na geração de alinhamentos de ontologia de alta qualidade.

Table 5
Resultados do experimento com o plugin *VIEW*, comparados aos dos participantes da Trilha Interativa da OAEI 2022 – Dataset Conference. A avaliação baseou-se no alinhamento de referência (ra1), com os resultados apresentados na seção da tabela referente à métrica de incerteza modelada como variável contínua [33].

Rank	Sistema	Precisão	Medida F	Cobertura
1	VIEW	1.00	0.74	0.61
2	LSMatch	0.88	0.67	0.54
3	KGMatcher+	0.88	0.65	0.51
4	ALIN	0.87	0.71	0.60
5	AMD	0.86	0.67	0.55
6	SEBMatcher	0.81	0.71	0.62
7	LogMap	0.80	0.66	0.57
8	ATMatcher	0.76	0.68	0.62
9	GraphMatcher	0.75	0.72	0.68
10	ALION	0.75	0.41	0.28
11	LogMapLt	0.72	0.67	0.63
12	Matcha	0.35	0.12	0.08
13	TOMATO	0.08	0.15	0.73

Figure 7: Resultados obtidos d0 plugin *VIEW* em comparação com os sistemas que participaram da Trilha Interativa - Dataset *Conference* - OAEI'2022.

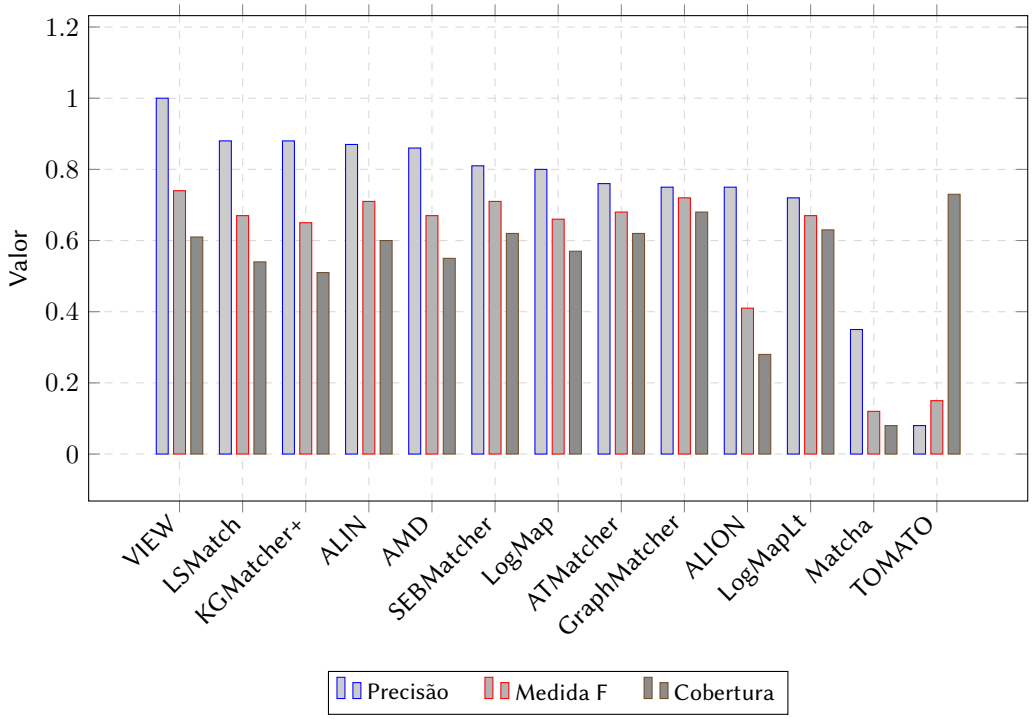

7. Considerações Finais

Para lidar com os desafios da heterogeneidade no alinhamento de ontologias do domínio da segurança cibernética em plantas de usinas nucleares (como Angra 1 e Angra 2), propôs-se uma abordagem baseada

em clusterização, utilizando o algoritmo K-Means em conjunto com três classificadores de *Machine Learning*: *Perceptron*, *Naive Bayes* e *Random Forest*. Com isso, foi desenvolvido o plugin *VIEW*, que incorpora essas técnicas ao processo de alinhamento interativo de ontologias.

A avaliação foi realizada no contexto da Trilha Interativa da OAEI, utilizando o dataset *Conference*, no período de 2022 a 2024. Os testes consideraram o alinhamento de referência (ra1), e os resultados foram bastante expressivos, demonstrando que o plugin *VIEW* é capaz de alinhar ontologias heterogêneas com bom desempenho, produzindo alinhamentos de alta qualidade.

Destaca-se, assim, a relevância de mapeamentos corretos para a segurança cibernética de sistemas críticos, uma vez que possibilitam a integração semântica e a interoperabilidade entre diferentes sistemas ciberfísicos em plantas de usinas nucleares. Em ambientes como esses — nos quais a disponibilidade, integridade e confidencialidade das informações são fatores essenciais —, o uso de mapeamentos bem definidos permite representar, alinhar e compartilhar conhecimento de forma estruturada e consistente entre ontologias de segurança cibernética. Isso facilita a detecção de inconsistências, a automação de respostas a incidentes e o monitoramento contínuo de ameaças, contribuindo para uma postura mais robusta e proativa na proteção de ativos críticos.

Como trabalho futuro, propõe-se investigar a combinação da abordagem atual com outras técnicas, com o objetivo de melhorar as métricas de cobertura e F-medida. Além disso, pretende-se aplicar o *VIEW* ao alinhamento de pares de ontologias especificamente voltadas ao domínio da segurança cibernética.

References

[1] A. Diegues, J. Roselino, *Política industrial, tecno-nacionalismo e indústria 4.0: a guerra tecnológica entre China e EUA*, Instituto de Economia - Universidade Estadual de Campinas (UNICAMP), 2021.

[2] S. H. H. N. Ghazani, J. J. Lotf, R. Aliguliyev, A study on qos models for mobile ad-hoc networks, International Journal of Modeling and Optimization 2 (2012) 634.

[3] S. Zeadally, N. Jabeur, Cyber-physical system design with sensor networking technologies, Institution of Engineering and Technology, 2016.

[4] J. Zeng, L. T. Yang, M. Lin, H. Ning, J. Ma, A survey: Cyber-physical-social systems and their system-level design methodology, Future Generation Computer Systems 105 (2020) 1028–1042.

[5] R. Alguliyev, Y. Imamverdiyev, L. Sukhostat, Cyber-physical systems and their security issues, Computers in Industry 100 (2018) 212–223. URL: https://www.sciencedirect.com/science/article/pii/S0166361517304244. doi:https://doi.org/10.1016/j.compind.2018.04.017.

[6] W. Lin, R. Haga, Matching cyber security ontologies through genetic algorithm-based ontology alignment technique, Security and Communication Networks 2021 (2021).

[7] F. Santos, C. E. Mello, Matching network of ontologies: A random walk and frequent itemsets approach, IEEE Access 10 (2022) 44638–44659. doi:10.1109/ACCESS.2022.3164067.

[8] X. Xue, W. Tan, Y. Tian, Matching cybersecurity ontologies on internet of everything through coevolutionary multiobjective evolutionary algorithm, Sec. and Commun. Netw. 2022 (2022). URL: https://doi.org/10.1155/2022/3572404. doi:10.1155/2022/3572404.

[9] ISO, ISO/IEC 27002:2013 - Information technology — Security techniques — Code of practice for information security controls, International Organization for Standardization, 2013.

[10] A. O. de Sá, L. F. R. d. C. Carmo, R. C. S. Machado, Covert attacks in cyber-physical control systems, IEEE Transactions on Industrial Informatics 13 (2017) 1641–1651. doi:10.1109/TII.2017.2676005.

[11] B. A. Mozzaquatro, C. Agostinho, D. Goncalves, J. Martins, R. Jardim-Goncalves, An ontology-based cybersecurity framework for the internet of things, Sensors 18 (2018). URL: https://www.mdpi.com/1424-8220/18/9/3053. doi:10.3390/s18093053.

[12] J. Euzenat, P. Shvaiko, Ontology matching, 2nd ed., Springer-Verlag, Heidelberg (DE), 2013.

[13] F. Shi, J. Li, J. Tang, G. Xie, H. Li, Actively learning ontology matching via user interaction, in: A. Bernstein, D. R. Karger, T. Heath, L. Feigenbaum, D. Maynard, E. Motta, K. Thirunarayan (Eds.), The Semantic Web - ISWC 2009, Springer Berlin Heidelberg, Berlin, Heidelberg, 2009, pp. 585–600.

[14] A. V. Kumar, K. N. Meera, Sentiment analysis using k means clustering on microblogging data focused on only the important sentiments, in: 2022 10th International Conference on Emerging Trends in Engineering and Technology - Signal and Information Processing (ICETET-SIP-22), 2022, pp. 1–5. doi:10.1109/ICETET-SIP-2254415.2022.9791723.

[15] X. Xu, Y. Li, Application implementation of k-means algorithm based on wolf pack algorithm, in: 2022 2nd Asia-Pacific Conference on Communications Technology and Computer Science (ACCTCS), 2022, pp. 402–404. doi:10.1109/ACCTCS53867.2022.00089.

[16] P. Tan, M. Steinbach, V. Kumar, Introduction to data mining, addison wesley publishers (2006).

[17] T. W. Shi, K. Moorthy, M. S. Mohamad, S. Deris, S. Omatu, M. Yoshioka, Random forest and gene ontology for functional analysis of microarray data, in: 2014 IEEE 7th International Workshop on Computational Intelligence and Applications (IWCIA), 2014, pp. 29–34. doi:10.1109/IWCIA.2014.6987731.

[18] X. Xue, H. Wang, Y. Zhao, Y. Huang, H. Zhu, Matching sensor ontologies with neural network, in: 2021 IEEE 20th International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom), 2021, pp. 1452–1457. doi:10.1109/TrustCom53373.2021.00206.

[19] X. Xue, D. Chen, W. Liu, Naive bayesian classifier based semi-supervised learning for matching ontologies, in: 2021 17th International Conference on Computational Intelligence and Security (CIS), 2021, pp. 162–167. doi:10.1109/CIS54983.2021.00042.

[20] J. Sampels, Ontomatch results for oaei 2024, in: Proceedings of the 19th International Workshop on Ontology Matching (OM-2024), volume 3897, CEUR-WS, 2024, pp. 124–131. URL: https://ceur-ws.org/Vol-3897/oaei24_paper5.pdf, collocated with ISWC 2024, Baltimore, USA.

[21] J. da Silva, K. Revoredo, F. A. Baião, C. Lima, Alin results for oaei 2024, in: Proceedings of the 19th International Workshop on Ontology Matching (OM-2024), volume 3897, CEUR-WS, 2024, pp. 118–123. URL: https://ceur-ws.org/Vol-3897/oaei24_paper4.pdf, collocated with ISWC 2024, Baltimore, USA.

[22] X. Liu, M. R. Hansen, J. Grode, Mdmapper results for oaei 2024, in: Proceedings of the 19th International Workshop on Ontology Matching (OM-2024), volume 3897, CEUR-WS, 2024, pp. 30–42. URL: https://ceur-ws.org/Vol-3897/oaei24_paperXX.pdf.

[23] E. Jiménez-Ruiz, Logmap family participation in the oaei 2024, in: Proceedings of the 19th International Workshop on Ontology Matching (OM-2024), volume 3897, CEUR-WS, 2024, pp. 161–162. URL: https://ceur-ws.org/Vol-3897/oaei24_paper10.pdf, collocated with ISWC 2024, Baltimore, USA.

[24] Y. Li, C. Stroe, I. F. Cruz, Interactive visualization of large ontology matching results, in: V. Ivanova, P. Lambrix, S. Lohmann, C. Pesquita (Eds.), Proceedings of the International Workshop on Visualizations and User Interfaces for Ontologies and Linked Data co-located with 14th International Semantic Web Conference (ISWC 2015), Bethlehem, Pennsylvania, USA, October 11, 2015, volume 1456 of *CEUR Workshop Proceedings*, CEUR-WS.org, 2015, p. 37. URL: http://ceur-ws.org/Vol-1456/paper4.pdf.

[25] S. M. Falconer, N. F. Noy, M.-A. Storey, Towards understanding the needs of cognitive support, in: Proceedings of the 1st International Conference on Ontology Matching - Volume 225, OM'06, CEUR-WS.org, Aachen, DEU, 2006, p. 25–36.

[26] I. F. Cruz, C. Stroe, M. Palmonari, Interactive user feedback in ontology matching using signature vectors, in: 2012 IEEE 28th International Conference on Data Engineering, 2012, pp. 1321–1324. doi:10.1109/ICDE.2012.137.

[27] S. Amrouch, S. Mostefai, Ascendant hierarchical clustering for instance matching, in: 2021 22nd International Arab Conference on Information Technology (ACIT), 2021, pp. 1–6. doi:10.1109/ACIT53391.2021.9677377.

[28] Y. Djenouri, H. Belhadi, K. Akli-Astouati, A. Cano, J. C.-W. Lin, An ontology matching approach for semantic modeling: A case study in smart cities, Computational Intelligence 38 (2022) 876–902. URL: https://onlinelibrary.wiley.com/doi/abs/10.1111/coin.12474. doi:https://doi.org/10.1111/coin.12474. arXiv:https://onlinelibrary.wiley.com/doi/pdf/10.1111/coin.12474.

[29] I. H. Witten, E. Frank, M. A. Hall, C. J. Pal, Data Mining, Fourth Edition: Practical Machine Learning Tools and Techniques, 4th ed., Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 2016.
[30] S. Chapman, String similarity metrics for information integration, Sam's String Metrics (2007).
[31] Y. Priyadi, A. Djunaidy, D. Siahaan, Requirements dependency graph modeling on software requirements specification using text analysis, in: 2019 1st International Conference on Cybernetics and Intelligent System (ICORIS), volume 1, 2019, pp. 221–226. doi:10.1109/ICORIS.2019.8874920.
[32] J. David, J. Euzenat, F. Scharffe, C. Trojahn dos Santos, The alignment api 4.0, Semantic web 2 (2011) 3–10.
[33] M. Pour, A. Algergawy, P. Buche, L. J. Castro, J. Chen, H. Dong, O. Fallatah, D. Faria, I. Fundulaki, S. Hertling, Y. He, I. Horrocks, M. Huschka, L. Ibanescu, E. Jimenez-Ruiz, N. Karam, A. Laadhar, P. Lambrix, H. Li, Y. Li, F. Michel, E. Nasr, H. Paulheim, C. Pesquita, T. Saveta, P. Shvaiko, C. Trojahn, C. Verhey, M. Wu, B. Yaman, O. Zamazal, L. Zhou, Results of the ontology alignment evaluation initiative 2022, in: 17th International Workshop on Ontology Matching (OM 2022), volume 3324, 2022, pp. 84–128. URL: https://openaccess.city.ac.uk/id/eprint/29879/.
[34] M. A. N. Pour, A. Algergawy, P. Buche, L. J. Castro, J. Chen, A. Coulet, J. Cufi, H. Dong, O. Fallatah, D. Faria, I. Fundulaki, S. Hertling, Y. He, I. Horrocks, M. Huschka, L. Ibanescu, S. Jain, E. Jimenez-Ruiz, N. Karam, P. Lambrix, H. Li, Y. Li, P. Monnin, E. Nasr, H. Paulheim, C. Pesquita, T. Saveta, P. Shvaiko, G. Sousa, C. Trojahn, J. Vatainová, M. Wu, B. Yaman, O. Zamazal, L. Zhou, Results of the ontology alignment evaluation initiative 2023, in: P. Shvaiko, J. Euzenat, E. Jimenez-Ruiz (Eds.), OM 2023 Ontology Matching, volume 3591, CEUR, Aachen, Germany, 2023, pp. 97–139. URL: https://ceur-ws.org/Vol-3591/oaei23%5fpaper0.pdf, © 2023 Copyright for this paper by its authors. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).
[35] M. A. N. Pour, A. Algergawy, E. Blomqvist, P. Buche, J. Chen, P. G. Cotovio, A. Coulet, J. Cufi, H. Dong, D. Faria, L. Ferraz, S. Hertling, Y. He, I. Horrocks, L. Ibanescu, S. Jain, E. Jiménez-Ruiz, N. Karam, F. Kraus, P. Lambrix, H. Li, Y. Li, P. Monnin, H. Paulheim, C. Pesquita, A. Sharma, P. Shvaiko, M. Silva, G. Sousa, C. Trojahn, J. Vatainová, B. Yaman, O. Zamazal, L. Zhou, Results of the ontology alignment evaluation initiative 2024, in: 19th International Workshop on Ontology Matching, volume 3897, 2025, pp. 64–97. URL: https://ceur-ws.org/Vol-3897/oaei2024%5fpaper0.pdf, © 2024 Copyright for this paper by its authors. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).